

MÉMOIRE PROFESSIONNEL MASTÈRE 1 CHEF DE PROJET DATA ET INTELLIGENCE ARTIFICIELLE

Optimisation IA – Maintenance Prédicative &
Expérience Voyageur SNCF



Date de début de projet : Octobre 2025

Nosaiba Elkreksi

Table des matières

1. Descriptif de l'entreprise – La SNCF	2
1.1 Storytelling : l'histoire de la SNCF	2
1.2 Les valeurs et missions	3
1.3 Activité principale.....	3
1.4 Environnement économique et sociétal	4
1.5 Environnement technologique	5
1.6 Environnement de données.....	6
2. Étude de marché et analyse concurrentielle	6
2.1 Analyse de marché.....	6
2.2 Analyse concurrentielle	8
3. Problématique et définition du besoin.....	12
3.1 Genèse de la problématique.....	12
3.2 La Problématique	12
3.3 Description fonctionnelle de la solution	12
3.4 Justification de la solution optimale	14
4. Pilotage du projet et planification	15
4.1 Choix de la méthode :.....	15
4.2 Retroplanning et livrables	16
4.3 Diagramme de Gantt.....	17
4.4 Tableaux de bord et KPIs.....	17
4.5 Estimation du budget	19
5. Exploitation des données	19
5.1 Identification des sources de données.....	19
5.2 Manipulation des tables et analyse.....	22
5.3 Visualisation des données	31
6. Conclusion	38
7. Annexes	41

1. Descriptif de l'entreprise – La SNCF

1.1 Storytelling : l'histoire de la SNCF

La SNCF est une Société Nationale des Chemins de Fer Français née le 1er janvier 1938, résultat d'une convention entre l'État français et les grandes compagnies de chemin de fer préexistantes, en application du décret-loi du 31 août 1937. À l'origine constituée sous la forme d'une société anonyme d'économie mixte, elle incarne dès sa fondation une ambition nationale forte : unifier et moderniser un réseau ferroviaire fragmenté au service de la cohésion du territoire.

Au fil des décennies, la SNCF traverse les grandes crises de l'histoire contemporaine française : la Seconde Guerre mondiale, la Reconstruction, les Trente Glorieuses. En 1981, l'inauguration de la première ligne TGV entre Paris et Lyon marque une révolution technologique mondiale : la France devient pionnière du train à grande vitesse, et la SNCF une référence internationale de premier plan. En 1983, l'entreprise prend le statut d'établissement public à caractère industriel et commercial (EPIC), renforçant son ancrage dans la sphère publique.

La réforme de 2018, dite « Pacte ferroviaire », restructure profondément le groupe en préparant l'ouverture à la concurrence et en transformant le modèle social (fin du statut cheminot pour les nouveaux entrants). Puis, le 1er janvier 2020, une transformation majeure s'opère : la SNCF devient une société anonyme à capitaux entièrement publics. L'État reprend 35 milliards d'euros de dettes, libérant la capacité d'investissement du groupe et lui offrant une structure plus agile, orientée vers la performance.

Aujourd'hui, le Groupe SNCF est un acteur mondial de la mobilité et de la logistique. Il se compose de cinq sociétés anonymes ferroviaires (SNCF, SNCF Réseau, SNCF Voyageurs, SNCF Gares & Connexions, Rail Logistics Europe) et de deux grandes filiales mondiales :

GEODIS (logistique, 170 pays) et Keolis (transport urbain, 5 continents). En 2024, le groupe a réalisé un chiffre d'affaires de 43,4 milliards d'euros et un bénéfice net de 1,6 milliard d'euros, pour la quatrième année consécutive bénéficiaire ¹.

1938 Année de création	290 000 Collaborateurs mondiaux	43,4 Md€ CA 2024	1,6 Md€ Bénéfice net 2024
---	--	-----------------------------------	--

¹ Autorité de Régulation des Transports (ART), Rapport annuel 2024

1.2 Les valeurs et missions

Le Groupe SNCF structure son action autour de quatre valeurs fondamentales guidant l'ensemble de ses décisions stratégiques et opérationnelles :

- **Excellence du service public** : Garantir à tous les citoyens un accès équitable à des transports de qualité, fiables et sûrs, quel que soit le territoire et le niveau de revenu.
- **Engagement pour la transition écologique** : La SNCF se positionne comme acteur central de la décarbonation des mobilités en France. Elle vise une réduction de 50 % de ses émissions CO2 d'ici 2030 (vs 2015). En 2024, ses émissions en France s'établissent à 1,4 million de tonnes de CO2, en baisse de 8 % par rapport à 2022.
- **Innovation et transformation numérique** : L'entreprise investit massivement dans l'intelligence artificielle, la data et le numérique pour améliorer la performance opérationnelle et l'expérience client. En mars 2025, la Direction numérique est rebaptisée « Direction numérique & IA ».
- **Responsabilité sociale et territoriale** : Premier recruteur de France avec 10 600 recrutements au semestre 1 de 2025, la SNCF joue un rôle majeur dans l'emploi et le développement des territoires, via la Fondation SNCF et ses partenariats avec les PME locales.

Sa mission première reste d'assurer la mobilité des personnes et des marchandises sur l'ensemble du territoire national, en offrant des solutions de transport compétitives, durables et accessibles. Elle contribue directement à l'aménagement du territoire, au désenclavement des zones rurales et à la décarbonation des déplacements.

1.3 Activité principale

Le Groupe SNCF est organisé autour de plusieurs pôles d'activité complémentaires, formant un écosystème de mobilité intégré :

SNCF Voyageurs	Transport ferroviaire de voyageurs en France et en Europe (TGV InOui, Ouigo, Intercités, TER, Transilien). Plus de 5,8 % de trafic en 2024.
SNCF Réseau	Gestion, entretien et développement du Réseau Ferré National (RFN) : 28 000 km de lignes.
SNCF Gares & Connexions	Exploitation de plus de 3 000 gares en France. Chiffre d'affaires (CA) en croissance de plus de 10,2 % au Semestre 1 en 2024.
Rail Logistics Europe	Transport ferroviaire de marchandises en Europe.

GEODIS	Logistique mondiale présente dans 170 pays. Plus de 11,5 Md€ de CA en 2024.
Keolis	Opérateur de transport urbain présent sur 5 continents. Plus de 9,6 % de trafic en 2024.

Un tiers du chiffre d'affaires du groupe est réalisé hors de France. Le groupe ambitionne de renforcer cette présence internationale, notamment via Keolis (Amérique du Nord, Asie, Europe du Nord) et GEODIS (logistique globale). En 2025, un consortium incluant la SNCF a remporté la réalisation de la première ligne LGV d'Amérique du Nord, entre Québec et Toronto (projet Cadence).²

1.4 Environnement économique et sociétal

Un marché ferroviaire en forte croissance

Le marché français du transport ferroviaire connaît une dynamique exceptionnelle. Selon l'Autorité de Régulation des Transports (ART), la fréquentation des trains a progressé de 6 % en 2024, battant un record pour la troisième année consécutive, avec 114 milliards de passagers kilomètres parcourus, soit 14 % au-dessus du niveau pré-Covid de 2019. L'offre ferroviaire a simultanément progressé de 7 % (412 millions de trains-kilomètres). La part modale du rail en France atteint 10,5 % en 2024, son plus haut niveau historique.

Cette dynamique s'explique par la convergence de plusieurs facteurs : prise de conscience environnementale des Français, politiques de décarbonation soutenues par l'État, développement de l'offre Ouigo à bas coûts (21 % de la fréquentation TGV en 2024), effet positif de l'ouverture à la concurrence sur les axes Paris-Lyon et France-Espagne.

114 Md Passagers-km 2024	+6% Croissance vs 2023	10,5% Part modale du rail	412 M Trains-km parcourus
---	---	--	--

L'ouverture à la concurrence :

Depuis 2020, le quatrième paquet ferroviaire européen impose l'ouverture progressive du marché ferroviaire à la concurrence. En France, cette ouverture se déploie sur les lignes TGV (Trenitalia depuis fin 2021, Renfe depuis 2023) et sur les TER via des appels d'offres régionaux (10 lots attribués sur les 50 prévus à mi-2025). Les effets sont déjà mesurables : sur l'axe Paris Lyon, la fréquentation a bondi de plus de 20 % depuis 2019, et les prix restent inférieurs d'environ 10 % aux niveaux pré-concurrence. Sur les liaisons France-Espagne, la hausse atteint 30 %.

² Groupe SNCF, Comment nous participons au projet de TGV au Canada. <https://www.groupe-sncf.com/fr/groupe/international/tgv-canada>

Contraintes légales et réglementaires :

La SNCF évolue dans un cadre réglementaire dense : 4ème paquet ferroviaire européen, Loi d'Orientation des Mobilités (LOM, 2019), régulation tarifaire de l'ART, RGPD pour la gestion des données voyageurs, DPEF et CSRD pour le reporting extra-financier. Les Jeux Olympiques de Paris 2024 ont représenté à la fois un défi opérationnel majeur et une vitrine internationale pour le groupe.

1.5 Environnement technologique

La SNCF se positionne résolument comme un acteur de la révolution numérique dans le secteur ferroviaire. Sa transformation technologique repose sur plusieurs piliers :

- L'Intelligence Artificielle générative et classique

Depuis janvier 2024, la SNCF a développé « Groupe SNCF GPT », son propre outil d'IA générative interne, permettant aux collaborateurs de travailler dans un environnement sécurisé exploitant des modèles de langage avancés. Plus de 20 000 salariés ont bénéficié de formations à ces outils. En mars 2025, la Direction numérique du groupe est rebaptisée « Direction numérique & IA » sous la direction de Julien Nicolas, avec dix cas d'usage IA prioritaires identifiés : relation client, maintenance prédictive, information voyageurs, génération de code, ressources humaines.

- La maintenance prédictive par la data

Le projet MARS LGV (Mobiles Autonomes de Reconnaissance en Sécurité), lancé en 2025, utilise des engins autonomes équipés de capteurs IA pour inspecter les lignes à grande vitesse. Le projet « Transformer » (depuis 2022) exploite le machine learning pour prédire en temps réel l'état du trafic et anticiper les retards. Le projet Open TCO (Computer Vision, 2024) analyse les aiguillages non informatisés via des caméras intelligentes, déployé à Paris-Lyon puis Strasbourg.

- L'application SNCF Connect et le protocole MCP

L'application SNCF Connect, utilisée par plus de 20 millions de personnes, constitue l'interface numérique majeure du groupe. Elle concentre les données de vente, de satisfaction et de mobilité. La SNCF explore l'intégration du Model Context Protocol (MCP) d'Anthropic. Bien que ce protocole soit très récent (lancé fin 2024), il est considéré comme une piste d'étude stratégique. L'objectif est de permettre aux grands modèles de langage d'accéder aux données open data du groupe de manière conversationnelle. Un premier cas d'usage, porté par la direction de l'innovation de SNCF Voyageurs (TGV-Intercités), vise à diffuser une information

voyageur conversationnelle, tout en maintenant une vigilance sur la sécurité informatique compte tenu de la jeunesse du protocole.³

1.6 Environnement de données

La SNCF gère un écosystème de données d'une ampleur considérable, structuré autour de plusieurs sources majeures :

- **Données opérationnelles** : Positions en temps réel des trains, état des voies, alertes de maintenance, consommation énergétique alimentées par des capteurs IoT (5 000 points de mesure en Île-de-France).
- **Données voyageurs** : Historiques de réservation, comportements d'achat sur SNCF Connect (20 M d'utilisateurs), données de fréquentation des gares via capteurs LiDAR.
- **Données d'infrastructure** : Cartographie du RFN (28 000 km), état des équipements, plans de maintenance, historique des incidents.
- **Données commerciales** : Grilles de prix dynamiques, taux d'occupation par train et par ligne, recettes de billetterie par point de vente (3 000+ gares).
- **Données météorologiques et externes** : Intégrées pour la maintenance prédictive (impact chaleur sur les rails, risques d'intempéries).

Le groupe gère ces données dans le cadre du RGPD, avec des mesures de sécurité renforcées. Sa politique Open Data rend disponibles de nombreux jeux de données sur transport.data.gouv.fr, contribuant à l'écosystème d'innovation ferroviaire français.

La SNCF est évaluée dans le top 1 % des entreprises par l'agence RSE EcoVadis (noté 89/100 en 2025).

2. Étude de marché et analyse concurrentielle

2.1 Analyse de marché

A. Dynamique et taille du marché

Le transport ferroviaire de voyageurs en France constitue l'un des marchés les plus dynamiques d'Europe. En 2024, selon l'ART (**Autorité de Régulation des Transports**), 114 milliards de passagers-kilomètres ont été parcourus (progression de 5 % sur un an et de 14 % par rapport à 2019)⁴. L'offre ferroviaire effective a augmenté de 7 %, portée tant par les services

³ LeMagIT, Open Data et IA : la SNCF prend son billet pour MCP, janvier 2026.

⁴ Autorité de Régulation des Transports (ART), *Rapport annuel 2024 sur le marché français du transport ferroviaire de voyageur*

conventionnés (TER, Intercités, Transilien-RER) que par les services à grande vitesse librement organisés.

Le chiffre d'affaires global du groupe SNCF atteint 43,4 milliards d'euros en 2024, en progression de 4,8 % vs 2023.

Cette dynamique s'explique par la convergence de facteurs structurels et conjoncturels : prise de conscience environnementale, politiques publiques de décarbonation (objectif de doubler le trafic ferroviaire d'ici 2030 selon la loi LOM) ⁵développement de l'offre Ouigo à bas coûts, et effets positifs de l'ouverture à la concurrence sur les axes concernés.

114 Md Passagers- km 2024	+14% vs niveau 2019	43,4 Md€ CA Groupe SNCF 2024	10,5% Part modale du rail
---------------------------------	------------------------	------------------------------------	------------------------------

B. Implantation et couverture du réseau

La France dispose du deuxième réseau ferroviaire d'Europe en longueur, avec 28 000 km de voies gérées par SNCF Réseau. Ce réseau couvre l'ensemble du territoire national, structuré autour d'un modèle radial centré à Paris (force sur les axes Paris-province, limite pour les liaisons inter-régionales). La SNCF gère plus de 3 000 gares sur l'ensemble du territoire.

À l'international, le groupe est présent dans plus de 170 pays via GEODIS et Keolis, et opère des services transfrontaliers vers l'Espagne, le Royaume-Uni, l'Allemagne, la Belgique et l'Italie.

C. Segmentation de la clientèle

Le marché ferroviaire français se segmente autour de quatre profils de voyageurs distincts aux besoins et attentes spécifiques :

- **Voyageurs d'affaires (Business)** : Très sensibles à la ponctualité et aux services premium. Représentent une part disproportionnée du chiffre d'affaires malgré un volume moindre. Grands utilisateurs des cartes d'abonnement professionnels et de la première classe.
- **Voyageurs loisirs long courrier** : Clients TGV en quête de rapport qualité-prix optimal. Très sensibles aux promotions et aux tarifs Ouigo. Forte saisonnalité (vacances scolaires, été). La Carte Avantage (plus de 5 millions de détenteurs) ⁶est le principal outil de fidélisation.

⁵ Loi d'Orientation des Mobilités (LOM), n°2019-1428 du 24 décembre 2019, Ministère des Transports

⁶ SNCF Voyageurs, *Données de fréquentation et satisfaction client 2023-2024*,

- **Navetteurs quotidiens (TER & Transilien) :** Utilisateurs réguliers des services régionaux et franciliens. Très sensibles à la ponctualité et au prix des abonnements. Représentent la majorité du trafic en volume.
- **Voyageurs internationaux :** Clients Eurostar, Thalys/Eurostar, Lyria, Renfe. Profil touristique ou professionnel européen.

D. Saisonnalité

Le marché ferroviaire français présente une saisonnalité marquée. Les périodes de pointe se concentrent sur les vacances scolaires (juillet-août, Noël, ponts de mai), avec des taux d'occupation pouvant dépasser 90 % sur les axes TGV.

En 2024, les Jeux Olympiques et Paralympiques de Paris ont généré un pic exceptionnel de fréquentation sur le réseau francilien (+25 % de sièges-km sur certaines lignes Transilien, Pass Rail en juillet-août pour les jeunes).

Les périodes creuses représentent un enjeu de remplissage important, stimulé par la politique tarifaire dynamique (yield management) de la SNCF.

E. Contraintes légales et réglementaires

La SNCF opère dans un cadre réglementaire dense à plusieurs niveaux : le 4ème paquet ferroviaire européen (ouverture à la concurrence), le règlement UE 2021/782 sur les droits des voyageurs, la Loi d'Orientation des Mobilités (LOM, 2019), la régulation tarifaire de l'ART, le RGPD pour les données voyageurs, et les nouvelles obligations de reporting climatique (CSRD). Ces contraintes réglementaires impliquent des investissements continus en conformité juridique et technique, ainsi qu'une transparence accrue vis-à-vis des régulateurs.

2.2 Analyse concurrentielle

L'ouverture du marché ferroviaire français à la concurrence depuis 2020 a modifié en profondeur le paysage concurrentiel de la SNCF. Si l'opérateur historique demeure ultra dominant représentant environ 85 % des parts de marché sur les services librement organisés (InOui 64 %, Ouigo 21 %), deux nouveaux entrants sérieux ont émergé, modifiant durablement les dynamiques tarifaires et commerciales.

Concurrent n°1 : Trenitalia France (Frecciarossa)

Trenitalia France, filiale du groupe ferroviaire public italien FS Italiane, est entrée sur le marché français en décembre 2021 avec le lancement de ses trains Frecciarossa sur l'axe Paris Lyon.

Cette arrivée a marqué une rupture historique : pour la première fois depuis la création de la SNCF en 1938, un opérateur étranger exploite des services commerciaux de voyageurs sur le territoire français. En 2024, Trenitalia France a capté 11 % de l'offre sur l'axe Paris-

Lyon, contre seulement 6 % en 2023, témoignant d'une montée en puissance rapide et continue. L'opérateur italien est passé de 9 à 14 allers-retours quotidiens depuis le 14 décembre 2025, renforçant sa présence commerciale.

Sur cet axe stratégique, les TGV InOui de la SNCF ne représentaient plus que 64 % de l'offre en 2024, contre 72 % avant l'arrivée de Trenitalia. Le reste de l'offre (21 %) est assuré par Ouigo, la marque low-cost du groupe SNCF. L'arrivée de Trenitalia a eu des effets bénéfiques mesurables pour l'ensemble du marché.

Le positionnement de Trenitalia France se distingue par une offre premium multi-classes : trois classes de service (Standard, Business, Executive) contre deux chez SNCF Voyageurs (Seconde et Première).

Malgré sa progression, Trenitalia France reste contraint à une seule liaison domestique (Paris Lyon-Chambéry), sans pouvoir proposer un réseau comparable à celui de la SNCF. Avec seulement 11 % de l'offre sur Paris-Lyon et moins de 2 % du total des services librement organisés en France (hors services conventionnés TER), Trenitalia demeure un acteur marginal à l'échelle du réseau national.

La méconnaissance de la marque « Frecciarossa » auprès du grand public français reste un frein commercial important, même si les campagnes de communication de l'opérateur se sont intensifiées depuis 2024.

Enfin, les coûts d'entrée sur le marché ferroviaire français sont élevés : péages d'infrastructure versés à SNCF Réseau, investissements lourds dans l'achat ou la location de matériel roulant homologué pour circuler en France, recrutement et formation de conducteurs certifiés, et négociations complexes avec les syndicats français.

Trenitalia France joue davantage un rôle de « régulateur de marché » que de concurrent existentiel pour la SNCF. Il pousse l'opérateur historique à améliorer son offre (ponctualité, confort des rames, notamment le TGV M prévu pour 2026) et à contenir ses prix sur l'axe Paris Lyon. Pour la SNCF, la réponse stratégique passe par l'amélioration continue de la qualité de service, l'innovation dans la relation client (application SNCF Connect, IA conversationnelle) et le renforcement de la fidélisation via la Carte Avantage et les programmes de récompenses.

Points positifs de Trenitalia en comparaison avec la SNCF : Trenitalia se distingue par une offre de classes supérieure à celle de la SNCF, avec trois niveaux de service (Standard, Business, Executive) contre deux chez l'opérateur français. Sa classe Executive, avec repas gastronomique inclus et design intérieur soigné, cible une clientèle d'affaires haut de gamme que la SNCF peine encore à fidéliser pleinement. Par ailleurs, l'arrivée de Trenitalia a eu un effet bénéfique indirect sur l'ensemble du marché : la pression concurrentielle a conduit à une baisse des prix d'environ 10 % sur l'axe Paris-Lyon, bénéficiant à tous les voyageurs.

Points négatifs de Trenitalia en comparaison avec la SNCF : Trenitalia reste extrêmement limité dans son développement français. Avec une seule liaison domestique (Paris-Lyon-Chambéry), il ne peut concurrencer le réseau national de 28 000 km de la SNCF. Sa notoriété auprès du grand public français demeure faible, contrairement à la forte reconnaissance de la marque SNCF. L'opérateur ne dispose d'aucun programme de fidélisation comparable à la Carte Avantage (5 millions de détenteurs), ni d'une application mobile de l'envergure de SNCF Connect (20 millions d'utilisateurs). Enfin, Trenitalia dépend entièrement de l'infrastructure gérée par SNCF Réseau, ce qui constitue une dépendance structurelle importante.

Concurrent n°2 : Renfe Viajeros (Espagne)

Renfe Viajeros, l'opérateur ferroviaire national espagnol, est entré sur le marché français en décembre 2022 avec le lancement de liaisons transfrontalières Lyon-Barcelone, puis en 2023 avec Marseille-Madrid.

Cette arrivée marque une étape importante dans l'intégration ferroviaire européenne et illustre la volonté des opérateurs nationaux historiques de conquérir de nouveaux marchés au-delà de leurs frontières. L'impact de Renfe sur le marché des liaisons France-Espagne est le plus spectaculaire de tous les nouveaux entrants. Avec 47 % de l'offre capturée sur ces liaisons transfrontalières en 2024, Renfe a véritablement transformé ce segment de marché jusqu'alors sous-exploité.

La hausse de fréquentation atteint 30 % par rapport au niveau de 2019, démontrant un puissant effet de création de marché : de nombreux voyageurs qui ne prenaient pas le train entre la France et l'Espagne le font désormais, attirés par des prix plus bas et une fréquence accrue des services. L'opérateur espagnol maîtrise parfaitement la gestion de lignes transfrontalières, avec une expertise acquise sur son réseau domestique où la concurrence ferroviaire est plus avancée qu'en France.

En Espagne, Renfe fait face depuis 2021 à la concurrence d'Ouigo España (filiale de la SNCF) et d'Iryo (opérateur privé détenu par des fonds d'investissement), qui ont respectivement capté 20 % et 15 % du marché espagnol de la grande vitesse en 2024.

Cette expérience concurrentielle a permis à Renfe d'affiner sa stratégie tarifaire et commerciale avant son arrivée en France.

Malgré ces succès, Renfe reste cantonné aux liaisons transfrontalières France-Espagne, sans présence sur le réseau domestique français.

La complémentarité avec les services SNCF est forte : Renfe utilise le réseau ferré géré par SNCF Réseau et dépend donc de son infrastructure. La gestion des liaisons internationales implique également des complexités supplémentaires : harmonisation des systèmes de signalisation entre la France et l'Espagne (passage du système TVM français au système

ERTMS européen), gestion des différences de gabarits et d'écartement des voies à la frontière (bien que les deux pays utilisent désormais le même écartement standard sur les lignes à grande vitesse), et coordination avec les autorités réglementaires des deux pays. Renfe Viajeros illustre parfaitement la logique de l'ouverture à la concurrence : en prenant position sur un marché transfrontalier sous-exploité, il a créé de la valeur mesurable pour les voyageurs (baisse des prix de -15 % en moyenne, hausse de l'offre de +40 % en nombre de trains quotidiens) tout en fragilisant modestement la position de SNCF Voyageurs sur ces liaisons spécifiques.

Pour la SNCF, cet exemple plaide pour une stratégie d'anticipation et de repositionnement tarifaire sur les liaisons susceptibles d'être concurrencées à moyen terme, plutôt qu'une posture défensive réactive.

Points positifs de Renfe en comparaison avec la SNCF :

Renfe dispose d'une expertise solide sur les liaisons transfrontalières, renforcée par son expérience de la concurrence ferroviaire en Espagne face à Ouigo España et Iryo. Son positionnement tarifaire agressif a permis de créer un marché jusqu'alors sous-exploité entre la France et l'Espagne, avec une hausse de fréquentation de 30 % et une baisse des prix de 15 % en moyenne. Ses trains AVE de dernière génération, capables de rouler à 300 km/h, offrent un niveau de confort comparable aux TGV français. Cette capacité à dynamiser un segment de marché constitue une leçon stratégique précieuse pour la SNCF sur ses propres liaisons.

Points négatifs de Renfe en comparaison avec la SNCF :

Renfe reste totalement absent du réseau ferroviaire domestique français, ce qui limite considérablement sa menace sur la position globale de la SNCF. Son expansion vers des liaisons intérieures (Paris-Marseille, Paris-Toulouse) se heurte à des contraintes réglementaires et techniques majeures : obtention de sillons, homologation du matériel roulant, recrutement de conducteurs certifiés. Contrairement à la SNCF qui maîtrise l'ensemble de la chaîne (infrastructure, exploitation, services), Renfe reste dépendant de SNCF Réseau pour accéder au territoire français. Son absence de services régionaux ou de banlieue le prive également d'un levier de fidélisation quotidien que possède pleinement la SNCF via le Transilien et les TER.

Synthèse de l'analyse concurrentielle

L'ouverture à la concurrence du marché ferroviaire français produit des effets déjà mesurables et majoritairement positifs pour les voyageurs : hausse de l'offre (+7 % de trains-km en 2024), baisse des prix en valeur réelle (-9 % depuis 2019 malgré l'inflation), et amélioration de la qualité de service (taux de ponctualité en hausse). Pour la SNCF, ces nouveaux entrants constituent davantage une opportunité d'amélioration qu'une menace

existentielle à court terme, compte tenu de leur présence encore limitée (environ 15 % cumulés du marché des services librement organisés en 2024).

3. Problématique et définition du besoin

3.1 Genèse de la problématique

L'analyse approfondie de la SNCF et de son environnement concurrentiel révèle une tension fondamentale : maintenir un réseau de 28 000 km en excellent état opérationnel tout en améliorant la qualité de service perçue par les voyageurs, dans un contexte de concurrence croissante, de hausse des coûts d'énergie et d'une pression réglementaire intense sur la ponctualité.

Les retards ferroviaires constituent le premier motif d'insatisfaction des voyageurs. Ils génèrent des coûts directs (indemnisations, pénalités contractuelles) et indirects (attrition clients, défiance envers le mode ferroviaire). Or, une grande partie de ces retards trouve son origine dans des pannes sur le matériel roulant et l'infrastructure qui auraient pu être anticipées par une meilleure exploitation des données de maintenance.

Parallèlement, l'ouverture à la concurrence exerce une pression tarifaire sur les lignes TGV, réduisant les marges commerciales. Dans ce contexte, la différenciation ne peut plus reposer uniquement sur le prix : elle doit s'appuyer sur la qualité d'exécution, la fiabilité et l'expérience voyageur. La SNCF dispose pour cela d'un actif concurrentiel unique : un écosystème de données massif (capteurs IoT, SNCF Connect, historiques de maintenance) que ses concurrents ne peuvent répliquer à court terme.

3.2 La Problématique

Comment la SNCF peut-elle exploiter ses données opérationnelles et voyageurs pour déployer un système de maintenance prédictive et d'optimisation de l'expérience client, permettant de réduire significativement les incidents de service et d'améliorer sa compétitivité face aux nouveaux entrants sur le marché ferroviaire français ?

3.3 Description fonctionnelle de la solution

La solution proposée s'articule autour d'un système intégré de Data Intelligence ferroviaire, structuré en trois modules fonctionnels complémentaires et progressivement déployables. Chaque module répond à un besoin métier précis identifié lors de l'analyse de l'environnement de la SNCF.

Module 1 – Maintenance Prédictive

Ce module vise à anticiper les défaillances du matériel roulant et de l'infrastructure en exploitant les données de capteurs IoT embarqués (système de télédiagnostic), les historiques de pannes et les conditions météorologiques. Il s'appuie sur des algorithmes de machine learning supervisé (régression, classification) pour prédire la probabilité de défaillance d'un équipement dans une fenêtre temporelle donnée (48h, 7 jours).

Sur le plan métier, ce module apporte à la SNCF trois bénéfices concrets et mesurables. Premièrement, il permet de réduire les interventions correctives d'urgence, sources de retards non planifiés et de coûts élevés, au profit d'une maintenance planifiée moins coûteuse et moins perturbatrice pour les voyageurs. Deuxièmement, il optimise l'allocation des équipes de maintenance en leur fournissant des alertes priorisées, évitant ainsi les interventions inutiles sur des équipements sains. Troisièmement, il contribue directement à l'amélioration de la ponctualité, premier indicateur de satisfaction des voyageurs et premier critère de différenciation face aux concurrents Trenitalia et Renfe.

Module 2 – Optimisation de la Ponctualité en Temps Réel

Ce module exploite les données de position en temps réel des trains, les données de trafic réseau et les historiques d'incidents pour optimiser dynamiquement les plans de transport en cas de perturbation. Des algorithmes de Deep Learning (réseaux de neurones récurrents, LSTM) modélisent les cascades de retards et proposent des stratégies d'atténuation.

Sur le plan métier, ce module permet aux équipes opérationnelles de la SNCF d'anticiper les perturbations en cascade plutôt que de les subir. Concrètement, lorsqu'un incident survient sur une ligne, le système calcule automatiquement l'impact probable sur les autres trains et propose des mesures correctives (réaffectation de matériel roulant, modification de tracés, information voyageurs proactive). Cela se traduit par une réduction des retards propagés, une meilleure gestion des correspondances et une diminution des indemnités versées aux voyageurs au titre des droits européens (règlement UE 2021/782).

Module 3 – Personnalisation de l'Expérience Voyageur

Exploitant les données de l'application SNCF Connect (20 millions d'utilisateurs) et les historiques de voyage, ce module propose une personnalisation avancée des services : recommandations adaptées, alertes proactives, offres commerciales ciblées, chatbot IA conversationnel.

Sur le plan métier, ce module transforme SNCF Connect d'un simple outil de billetterie en une plateforme de relation client intelligente. Pour la SNCF, cela représente un levier de fidélisation puissant face à la concurrence : un voyageur qui reçoit des alertes personnalisées, des offres adaptées à ses habitudes de voyage et une assistance proactive en cas de perturbation est un voyageur moins susceptible de choisir Trenitalia ou Renfe. Ce module contribue également à

augmenter le revenu moyen par voyageur grâce aux recommandations commerciales ciblées (vente additionnelle de services à bord, offres de fidélité dynamiques).

3.4 Justification de la solution optimale

Avant de retenir cette solution, plusieurs alternatives ont été étudiées et écartées pour les raisons suivantes.

Alternative 1 — Investissement massif dans le renouvellement du matériel roulant

Une première approche aurait consisté à répondre aux problèmes de fiabilité uniquement par le renouvellement accéléré du parc ferroviaire. Si cette option présente des avantages indéniables en termes de fiabilité structurelle, elle se heurte à des contraintes majeures : des délais de déploiement de 5 à 10 ans, des investissements de plusieurs milliards d'euros, et surtout l'absence de valeur ajoutée immédiate pour l'expérience voyageur. Elle n'exploite pas les données déjà disponibles et n'apporte aucune réponse à la problématique de personnalisation du service.

Alternative 2 — Développement d'une nouvelle application mobile

Une deuxième option aurait été de concentrer les efforts sur la refonte complète de SNCF Connect. Bien que pertinente pour l'expérience voyageur, cette approche ne traite pas les causes profondes des retards et des incidents, qui restent d'ordre opérationnel et infrastructure. Une meilleure application ne compense pas un train en panne ou en retard.

Alternative 3 — Externalisation de la maintenance à un prestataire spécialisé

Une troisième piste aurait été de confier la maintenance à un opérateur externe spécialisé. Cette option présente le risque de perdre la maîtrise de données opérationnelles sensibles, de créer une dépendance stratégique vis-à-vis d'un tiers, et de ne pas capitaliser sur l'immense patrimoine de données que la SNCF a constitué depuis des décennies.

Pourquoi la solution retenue est optimale

La solution en trois modules s'impose comme la plus pertinente pour quatre raisons fondamentales. Premièrement, elle adresse simultanément les deux sources d'insatisfaction les plus documentées chez les voyageurs : les retards et la qualité de service perçue. Deuxièmement, elle capitalise sur les investissements data déjà engagés par la SNCF (capteurs IoT, SNCF Connect, historiques de maintenance), évitant ainsi de repartir de zéro. Troisièmement, elle génère des économies mesurables dès la phase pilote, avec une réduction estimée à 20 % des coûts de maintenance corrective, conformément aux standards industriels de la maintenance 4.0. Quatrièmement, elle positionne la SNCF comme leader technologique face à ses concurrents, qui ne disposent pas d'un écosystème de données comparable à court terme. Enfin, sa structure modulaire permet un déploiement progressif et maîtrisé, limitant les

risques opérationnels et financiers inhérents à tout projet de transformation numérique de grande envergure.

4. Pilotage du projet et planification

4.1 Choix de la méthode :

Trois méthodes de gestion de projet ont été étudiées avant de retenir la plus adaptée au contexte de ce projet : Lean, Kanban et Agile Scrum.


La méthode Lean repose sur l'élimination des gaspillages et l'optimisation des flux de valeur. Si elle est particulièrement efficace dans les contextes industriels et de production répétitive, elle s'adapte moins bien à un projet de développement de modèles de Machine Learning, où les itérations, les expérimentations et les ajustements fréquents sont inhérents à la démarche scientifique. Le Lean suppose en effet une certaine stabilité des processus et une vision claire du résultat final dès le départ, ce qui n'est pas le cas ici : les performances des modèles ne sont connues qu'après entraînement et validation.

La méthode Kanban est un excellent outil de visualisation et de gestion du flux de tâches en continu. Elle est cependant plus adaptée à des équipes gérant un flux constant de petites tâches opérationnelles qu'à un projet structuré en grandes phases avec des livrables définis. Elle ne prévoit pas de rituels formels de planification ni de revues périodiques, ce qui rendrait difficile le suivi d'avancement auprès des parties prenantes métier de la SNCF.

La méthode Agile Scrum a été retenue pour ce projet pour trois raisons fondamentales. Premièrement, elle est parfaitement adaptée à la complexité et à l'incertitude inhérentes au développement de modèles de Machine Learning : les sprints de deux semaines permettent d'ajuster régulièrement les orientations techniques en fonction des résultats obtenus. Deuxièmement, elle garantit des livraisons incrémentales de valeur, permettant aux équipes métier de la SNCF de valider et tester chaque module progressivement plutôt que d'attendre la fin du projet pour voir un résultat. Troisièmement, ses rituels structurés (Daily Stand-up, Sprint Planning, Sprint Review, Retrospective) assurent une communication fluide et une traçabilité rigoureuse de l'avancement, essentielle dans un contexte de projet à 455 000 euros impliquant plusieurs parties prenantes.

Dans le cadre de ce projet conduit en autonomie, les rituels Scrum ont été adaptés avec des points d'avancement hebdomadaires et des revues de phase mensuelles, permettant un suivi rigoureux de l'avancement technique et budgétaire.

Cycle Agile Scrum — Projet IA & Maintenance Prédictive SNCF



4.2 Retroplanning et livrables

Le projet est planifié sur 9 mois (octobre 2025 – juin 2026), découpé en six phases avec des jalons et livrables précis associés à chaque étape.

Phase 1 — Cadrage (Octobre – Novembre 2025)

Définition du périmètre, constitution de l'équipe, mise en place de l'environnement de travail.

Livrable : Charte de projet + Architecture technique validée.

Phase 2 — Collecte de données et Analyse Exploratoire (Novembre – Décembre 2025)

Collecte, nettoyage et exploration des données opérationnelles et voyageurs.

Livrable : Rapport EDA + Dictionnaire de données.

Phase 3 — Module Maintenance Prédictive (Janvier – Février 2026)

Développement et validation du modèle Random Forest.

Livrable : Modèle validé baseline open data (F1 0,639 / AUC 0,701), cible production F1 > 0,85

Phase 4 — Module Ponctualité (Mars – Avril 2026)

Développement du modèle LSTM pour la prédiction des retards.

Livrable : Modèle LSTM validé (MAE < 3 %, RMSE < 3 %).

Phase 5 — Module Expérience Voyageur (Avril – Mai 2026)

Développement du moteur de recommandation et du chatbot IA.

Livrable : Prototype fonctionnel + Plan de déploiement.


Phase 6 — Tests, Documentation et Préparation au déploiement (Mai – Juin 2026)

Tests d'intégration, documentation finale et préparation au déploiement.

Livrable : Rapport de tests + Manuel utilisateur.

4.3 Diagramme de Gantt

Le diagramme de Gantt représente la planification des grandes phases avec des chevauchements partiels pour optimiser les délais et tenir compte du calendrier condensé de 9 mois.



4.4 Tableaux de bord et KPIs

Le pilotage de ce projet repose sur un double système d'indicateurs complémentaires. Les KPIs de gestion de projet permettent de suivre l'avancement opérationnel et le respect des délais et du budget, tandis que les KPIs métiers et techniques mesurent la performance réelle des

modèles développés et leur impact sur les objectifs business de la SNCF. Ce double système garantit une vision à la fois micro (sprint par sprint) et macro (résultats finaux attendus).

Tableau 1 : KPIs Gestion de Projet :

KPI	Cible	Fréquence de mesure	Méthode de mesure
Vélocité Scrum	30-35 points/sprint	Fin de chaque sprint	Comptage des story points complétés
Taux de complétion sprints	>85%	Bimensuel	Ratio tâches terminées / planifiées
Budget consommé vs prévu	±5%	Mensuel	Comparaison budget prévisionnel / réel
Respect du planning	>90%	Mensuel	Comparaison dates prévues / réelles

Tableau 2 : KPIs Métiers/Techniques :

KPI	Cible	Méthode de mesure
F1-Score (maintenance prédictive)	> 0,85	Validation croisée 5-fold
AUC-ROC (prédiction incidents)	> 0,90	Évaluation sur jeu de test
MAE ponctualité	< 3 %	Écart prédiction/valeur réelle
RMSE	< 3 %	Écart prédiction / valeur réelle
Taux réduction incidents	-15%	Comparaison avant/après pilote
NPS Voyageur (Score Net de Promotion)	Progression +5 pts	Enquêtes satisfaction

Pour le LSTM, les pourcentages désignent des points de pourcentage d'écart sur le taux de régularité prédit.

Les cibles $F1 > 0,85$ et $AUC > 0,90$ sont des objectifs de mise en production, atteignables avec les données granulaires internes. Sur les données open data agrégées disponibles en phase académique, le modèle honnête établit une Baseline de $F1\ 0,639$ et $AUC\ 0,701$; l'écart avec la cible mesure le gain attendu de l'enrichissement des données.

4.5 Estimation du budget

Poste	Montant	Justification
RH équipe data (profil cible)	260 000€	6 profils sur 9 mois (chef de projet, data scientists, engineers, analyst)
Infrastructure Cloud	60 000 €	Hébergement, GPU, stockage sur 9 mois
Licences logicielles	20 000 €	Python, Power BI, Jira, monitoring
Données externes	12 000 €	Données météo, benchmarking
Formations	15 000 €	ML, deep learning, certifications cloud
Pilote & production	45 000 €	Déploiement sur périmètre restreint
Réserve aléas (10%)	43 000 €	Imprévus techniques et organisationnels
Total	455 000 €	ROI attendu sous 18 mois

Ce projet a été conduit en totale autonomie. Le budget de l'équipe-type recommandée pour un déploiement industriel réel, distinct du travail académique individuel réalisé ici.

Exploitation des données

5.1 Identification des sources de données

A. Identification des sources et formats

Pour répondre à la problématique retenue, trois jeux de données open data mis à disposition par la SNCF sur son portail officiel (ressources.data.sncf.com) ont été sélectionnés. Ces données sont accessibles librement sous licence Open Database License (ODbL) et constituent une base solide pour alimenter les trois modules du système de Data Intelligence ferroviaire.

Source 1 — Régularité mensuelle TGV nationale (CSV)

Ce jeu de données fournit les indicateurs globaux de ponctualité des TGV à l'échelle nationale sur une base mensuelle. Il constitue la source de référence pour mesurer

l'évolution de la performance ferroviaire dans le temps et identifier les tendances et saisonnalités.

Source 2 — Régularité mensuelle TGV par liaisons (CSV)

Ce jeu de données est le plus riche et le plus stratégique pour notre projet. Il détaille la performance de chaque liaison TGV (par paire gare de départ / gare d'arrivée) sur une base mensuelle, avec le détail des causes de retards ventilées par catégorie. Il constitue le cœur de l'analyse pour le module de maintenance prédictive.

Source 3 — Fréquentation des gares (CSV)

Ce jeu de données recense le nombre annuel de voyageurs par gare sur l'ensemble du réseau SNCF de 2015 à 2024. Il alimente le module d'optimisation de l'expérience voyageur en permettant d'identifier les gares à fort trafic et d'analyser les tendances de fréquentation.

B. Évaluation de la volumétrie

Le tableau ci-dessous présente la volumétrie précise de chacune des trois sources de données :

Sources	Format	Nb de lignes	Nb de colonnes	Période couverte
Régularité TGV nationale	CSV	135	3	Janvier 2015 - Présent
Régularité TGV par liaisons	CSV	12 181	26	Janvier 2018 - Présent
Fréquentation des gares	CSV	3 021	27	2015 – 2024
Total		15 337		

L'ensemble représente un volume de données modeste en taille fichier (données textuelles structurées), mais d'une grande richesse analytique avec 15 337 enregistrements et 56 variables au total. Le Dataset 2, avec ses 12 181 lignes et 26 colonnes, constitue à lui seul l'essentiel de la valeur analytique du projet.

C. Dictionnaire de données

Le dictionnaire de données ci-dessous recense les variables clés qui seront utilisées dans les modèles de Machine Learning, avec leur description fonctionnelle et leurs valeurs types :

Variable	Dataset	Rôle dans le modèle	Valeurs types
pct_cause_materiel_roulant	DS2	Variable cible principale, maintenance prédictive	0 à 100 %
pct_cause_infra	DS2	Variable explicative, état infrastructure	0 à 100 %
retard_moyen_arrivee	DS2	Variable cible, module ponctualité	0 à 60 min
nb_train_retard_sup_15	DS2	Indicateur de performance opérationnelle	Entier positif
nb_annulation	DS2	Indicateur d'incidents graves	Entier positif
regularite_composite	DS1	Indicateur global de performance	85 à 95 %
total_voyageurs_2024	DS3	Volume de trafic par gare	400 000 à 260 M
date	DS1/DS2	Variable temporelle pour séries chronologiques	Format AAAA-MM

D. Respect de la réglementation sur la collecte et l'usage des données

Conformité RGPD

Les trois jeux de données utilisés dans ce projet sont des données agrégées et anonymisées qui ne contiennent aucune donnée à caractère personnel au sens du Règlement Général sur la Protection des Données (RGPD — Règlement UE 2016/679). Il s'agit exclusivement de statistiques opérationnelles (taux de ponctualité, nombre de trains, fréquentation par gare) sans aucune information permettant d'identifier directement ou indirectement un individu.

Points de contrôle RGPD appliqués :

Point de contrôle	Statut	Justification
Absence de données personnelles	Conforme	Données agrégées statistiques uniquement
Base légale du traitement	Conforme	Licence ODbL — usage académique autorisé
Minimisation des données	Conforme	Seules les variables utiles à l'analyse sont conservées

Sécurisation des données	Conforme	Données stockées dans un environnement Google Colab sécurisé
Droit d'accès et transparence	Conforme	Sources publiques citées et référencées

Conformité licence ODbL (Open Database License)

Les données SNCF open data sont publiées sous licence ODbL, dont les conditions ont été acceptées lors du téléchargement. Cette licence impose trois obligations respectées dans ce projet : l'attribution de la source (les données sont citées avec leur URL d'origine dans les annexes), le partage à l'identique pour toute base dérivée publiée, et l'ouverture des données dérivées si elles sont redistribuées.

Point de contrôle spécifique au projet

Dans le cadre du module 3 (Expérience Voyageur), si des données comportementales issues de SNCF Connect venaient à être intégrées en phase de production, un traitement spécifique des données personnelles des voyageurs serait nécessaire. Cela impliquerait : la nomination d'un Délégué à la Protection des Données (DPO), la réalisation d'une Analyse d'Impact relative à la Protection des Données (AIPD), la mise en place d'une politique de consentement explicite, et le respect des droits des personnes (droit d'accès, de rectification, d'effacement). Ces mesures sont documentées dans le plan de déploiement du module 3 et constituent un prérequis à toute mise en production.

5.2 Manipulation des tables et analyse

A. Installation de la base de données

Afin de centraliser et structurer les trois sources de données dans un environnement cohérent, une base de données relationnelle SQLite a été créée sous Python via la bibliothèque sqlite3. SQLite a été retenu pour sa légèreté, sa portabilité et son intégration native avec Python, sans nécessiter de serveur dédié, ce qui est parfaitement adapté à la phase de développement et de prototypage de ce projet. La base de données, nommée `snCF_maintenance.db`, a été créée avec succès et contient trois tables correspondant aux trois sources de données identifiées :

Table	Enregistrements	Description
<code>regularite_tgv</code>	138	Régularité mensuelle TGV nationale
<code>liaisons_tgv</code>	12 544	Régularité TGV par liaisons
<code>frequentation_gares</code>	3 021	Fréquentation annuelle des gares


```
=====
ÉTAPE 1 – INSTALLATION BASE DE DONNÉES SQLITE
=====
Base de données 'sncf_maintenance.db' créée avec succès

Tables disponibles dans la base :
→ regularite_tgv
→ liaisons_tgv
→ frequentation_gares

Vérification du contenu :
→ regularite_tgv : 138 enregistrements
→ liaisons_tgv : 12544 enregistrements
→ frequentation_gares : 3021 enregistrements
```

La base a d'abord été chargée avec les données live (12 544 lignes pour les liaisons, 138 mois pour la régularité nationale), puis la période d'analyse a été figée au 31 mars 2026 (12 181 lignes, 135 mois) afin de garantir la reproductibilité des résultats. C'est ce jeu figé qui alimente toute la modélisation.

B. Analyse des valeurs manquantes et des incohérences

L'analyse des valeurs manquantes a été réalisée sur les trois datasets avant tout traitement. Les résultats sont les suivants :

Dataset 1 — Régularité TGV nationale : Aucune valeur manquante détectée sur les 135 enregistrements. La colonne date a été convertie du format texte (object) au format datetime pour permettre les analyses temporelles. La période couverte s'étend de janvier 2015 à mars 2026, soit 135 mois d'historique.

Dataset 2 — Régularité TGV par liaisons : Trois colonnes présentaient des valeurs manquantes à 100% : commentaire_annulation (12 544 valeurs manquantes), commentaire_retards_depart (12 544 valeurs manquantes) et commentaires_retard_arrivee (11 846 valeurs manquantes). Ces colonnes étant des champs texte libres non renseignés et sans valeur analytique, elles ont été supprimées conformément au principe de minimisation des données. Après nettoyage, le dataset ne présente plus aucune valeur manquante et compte désormais 23 colonnes exploitables au lieu de 26.

Dataset 3 — Fréquentation des gares : Trois colonnes catégorielles présentaient des valeurs manquantes minoritaires : direction_regionale_gares (11 valeurs), segmentation_drg (70 valeurs) et segmentation_marketing (125 valeurs). Ces valeurs

manquantes ont été remplacées par la modalité "Non renseigné", préservant ainsi l'intégralité des 3 021 enregistrements sans introduire de biais dans l'analyse.

L'analyse des statistiques descriptives du Dataset 2 révèle des informations importantes pour la modélisation :

Indicateur	Moyenne	Médiane	Min	Max
Retard moyen arrivée (min)	35,21	33,50	-40,11	299,60
Nb trains retard > 15 min	27,09	22,00	0	312
% cause matériel roulant	18,88%	17,02%	0%	100%
% cause infrastructure	21,77%	20,00%	0%	100%

Précisons que cet indicateur correspond à la moyenne des retards moyens à l'arrivée calculés par liaison et par mois, et non à une moyenne sur l'ensemble des circulations individuelles : il ne doit donc pas se lire comme « tous les TGV accusent 35 minutes de retard ». La valeur minimale négative (-40,11 min) correspond à de rares couples liaison-mois où les trains sont arrivés en avance en moyenne, et constitue une valeur extrême isolée.

Ces statistiques confirment que le matériel roulant représente en moyenne 18,88% des causes de retards, ce qui justifie pleinement le développement d'un module de maintenance prédictive ciblant cette variable.

```
=====
ÉTAPE 2 – ANALYSE ET NETTOYAGE DES DONNÉES
=====
```

```
--- Dataset 1 : Régularité TGV nationale ---
```

```
Valeurs manquantes avant nettoyage :
```

```
date            0
regularite_composite  0
ponctualite_origine  0
dtype: int64
```

```
Colonne 'date' convertie en datetime
```

```
Période couverte : 2015-01-01 00:00:00 → 2026-06-01 00:00:00
```

```
Valeurs manquantes après nettoyage : 0
```

--- Dataset 2 : Régularité TGV par liaisons ---

Valeurs manquantes AVANT nettoyage :

commentaire_annulation 12544

commentaire_retards_depart 12544

commentaires_retard_arrivee 11846

dtype: int64

Colonnes commentaires supprimées (100% valeurs manquantes)

Colonne 'date' convertie en datetime

Valeurs manquantes APRÈS nettoyage : 0

Dimensions finales : 12544 lignes x 23 colonnes

--- Dataset 3 : Fréquentation gares ---

Valeurs manquantes AVANT nettoyage :

direction_regionale_gares 11

segmentation_drg 70

segmentation_marketing 125

dtype: int64

Valeurs manquantes remplacées par 'Non renseigné'

Valeurs manquantes APRÈS nettoyage : 0

Dimensions finales : 3021 lignes x 27 colonnes

C. Sécurisation des données

Plusieurs mesures de sécurisation ont été mises en place pour garantir l'intégrité et la confidentialité des données tout au long du projet :

Mesure	Description	Statut
Sauvegarde locale des données nettoyées	Export CSV des trois datasets après nettoyage	Appliqué
Base de données SQLite sécurisée	Fichier sncf_maintenance.db avec accès contrôlé	Appliqué
Environnement isolé	Traitement dans Google Colab (environnement sandbox)	Appliqué
Absence de données personnelles	Vérification confirmée , données agrégées uniquement	Vérifié
Traçabilité des traitements	Chaque transformation est documentée et commentée dans le code	Appliqué
Conformité licence ODbL	Sources citées, usage académique non commercial	Conforme

```
=====
ÉTAPE 3 – SÉCURISATION DES DONNÉES
=====
Fichiers nettoyés sauvegardés localement
Base de données mise à jour avec les données nettoyées
Taille de la base de données : 2764.0 Ko

--- Statistiques descriptives Dataset 2 ---
      retard_moyen_arrivee  nb_train_retard_sup_15  \
count      12181.00      12181.00
mean         35.21         27.09
std          15.55         22.86
min          -40.11          0.00
25%           25.81         11.00
50%           33.50         22.00
75%           42.46         37.00
max           299.60        312.00

      prct_cause_materiel_roulant  prct_cause_infra
count      12181.00      12181.00
mean         18.88         21.77
std          13.49         14.87
min           0.00          0.00
25%           10.00         11.76
50%           17.02         20.00
75%           25.37         29.41
max           100.00        100.00

Connexion base de données fermée proprement
```

D. Analyse des données avec algorithmes de machine learning et deep learning

Choix des algorithmes et justification

Deux algorithmes complémentaires ont été sélectionnés pour répondre aux deux dimensions de la problématique. Le premier problème estimer un risque à partir de variables tabulaires sans ordre temporel (volumes, retards, annulations d'un mois-liaison) — est un problème de classification sur données structurées. Le Random Forest y est particulièrement adapté : il capture les relations non linéaires entre variables, résiste au sur-apprentissage grâce à l'agrégation d'arbres, ne nécessite pas de normalisation, et fournit nativement une mesure d'importance des variables, précieuse pour l'interprétabilité attendue par les équipes métier. Comparé à une régression logistique (trop linéaire) ou à un gradient boosting (plus performant mais plus sensible au réglage et moins lisible), il offre le meilleur compromis performance / robustesse / interprétabilité pour un premier déploiement.

Le second problème prédire l'évolution du taux de régularité mois après mois est un problème de série temporelle, où l'ordre des observations et la mémoire du passé sont essentiels. Le LSTM (Long Short-Term Memory) est un réseau de neurones récurrent conçu précisément pour cela : sa mémoire cellulaire lui permet de retenir des dépendances longues (saisonnalité sur 12 mois) que le Random Forest, aveugle à l'ordre temporel, ne peut modéliser. C'est cette complémentarité un modèle pour le tabulaire, un modèle pour le séquentiel qui justifie l'emploi des deux plutôt que d'un seul.

Les hyperparamètres du Random Forest (100 arbres, profondeur maximale 10, minimum 5 observations par nœud, classes équilibrées) ont été choisis pour limiter le

sur-apprentissage sur un jeu de taille modérée, et validés par une validation croisée 5-fold dont la faible écart-type ($\pm 0,005$) confirme la stabilité. Une optimisation systématique par GridSearchCV constitue la prochaine étape d'amélioration.

Modèle 1 — Random Forest Classifier (Machine Learning supervisé)



L'algorithme Random Forest a été retenu pour le module de maintenance prédictive. Il s'agit d'un algorithme d'apprentissage supervisé de type classification, fondé sur un ensemble d'arbres de décision entraînés en parallèle sur des sous-échantillons aléatoires des données et des variables, ce qui réduit le sur-apprentissage et améliore la robustesse. La prédiction finale résulte d'un vote majoritaire entre les arbres.

La variable cible est une variable binaire « risque_materiel », définie à partir de la médiane de la colonne prct_cause_materiel_roulant (seuil = 17,02 %) : la valeur 1 indique un mois-liaison où le matériel roulant est une cause majoritaire de retard, la valeur 0 un risque faible.

Un point méthodologique déterminant a guidé la sélection des variables explicatives. Les six catégories de causes de retard (externe, infrastructure, gestion du trafic, gestion en gare, prise en charge voyageurs, matériel roulant) constituent une décomposition en pourcentages d'un même total : elles sont donc algébriquement liées entre elles. Les inclure comme variables d'entrée aurait introduit une fuite d'information (data leakage): connaissant cinq parts sur six, le modèle peut reconstituer la sixième c'est-à-dire la cible sans réellement apprendre. Ces six variables ont par conséquent été écartées. Le modèle a été entraîné uniquement sur des variables opérationnelles indépendantes de la cible : nombre de trains prévus, durée moyenne, retards moyens au départ et à l'arrivée, nombres de trains en retard (> 15 , > 30 , > 60 min) et nombre d'annulations.

Le dataset de 12 181 observations a été divisé en un jeu d'entraînement (70%) contenant 8 526 observations et un jeu de test (30%) contenant 3 655 observations, conformément aux exigences du cahier des charges. Aucune normalisation n'est nécessaire : le Random Forest est insensible à l'échelle des variables.

Le modèle a été configuré avec 100 arbres (`n_estimators=100`), une profondeur maximale de 10 niveaux (`max_depth=10`), un minimum de 5 observations par nœud (`min_samples_split=5`) et un équilibrage automatique des classes (`class_weight='balanced'`).





Modèle 2 — LSTM (Deep Learning — Séries temporelles)

Le modèle LSTM (Long Short-Term Memory) est un type de réseau de neurones récurrents spécialement conçu pour modéliser les dépendances temporelles à long terme dans les séries chronologiques. Contrairement aux réseaux de neurones classiques, le LSTM dispose d'une mémoire cellulaire qui lui permet de retenir des informations sur des fenêtres temporelles étendues, ce qui le rend particulièrement adapté à la prédiction de la régularité mensuelle des TGV.

Le modèle a été entraîné sur la série temporelle de régularité composite des TGV (Dataset 1, 135 mois d'historiques de janvier 2015 à mars 2026, 123 séquences, 37 en test. Une fenêtre glissante de 12 mois a été utilisée pour créer les séquences d'entraînement : le modèle prédit le taux de régularité du mois M+1 à partir des 12 mois précédents. Cela a permis de générer 123 séquences au total. Les données ont été normalisées entre 0 et 1 via un MinMaxScaler avant entraînement.

L'architecture du réseau LSTM comprend deux couches LSTM successives (50 et 25 neurones), des couches Dropout de 20% pour prévenir le sur-apprentissage, et une couche Dense finale pour la prédiction. Le modèle totalise 18 026 paramètres entraînaibles.





E. Évaluation des performances des modèles

Évaluation du modèle Random Forest

Métrique	Valeur obtenue	Objectif KPI	Statut
Accuracy	63,86%	/	/
F1-Score(pondéré)	0,6386	> 0,85	Éloigné
AUC-ROC	0,7009	> 0,90	Non atteint
F1-Score	0,6420 ± 0,0050	/	Stable

Sur des données strictement indépendantes de la cible, le modèle atteint une AUC-ROC de 0,7009 et un F1-Score de 0,638 , avec une validation croisée 5-fold stable ($0,6420 \pm 0,0050$). Ces performances, honnêtes, sont volontairement présentées sans fuite d'information : une première version incluant les parts de causes de retard atteignait une AUC de 0,916, mais ce score était artificiel, les causes étant algébriquement liées à la cible (leur somme est fixe). Cette version a été écartée au profit d'un modèle méthodologiquement rigoureux.

L'analyse de l'importance des variables du modèle honnête est cohérente avec la réalité opérationnelle : les variables les plus prédictives sont le retard moyen au départ, le volume de trains prévus et les retards moyens à l'arrivée. Autrement dit, l'intensité et la propagation des retards portent une information réelle mais limitée sur l'implication du matériel roulant.

Cet écart entre 0,70 et l'objectif de 0,90 n'est pas un échec : il est le résultat central du projet. Il démontre quantitativement que les données open data agrégées (mensuelles, par liaison) ne suffisent pas à une maintenance réellement prédictive. Atteindre les cibles de production suppose l'accès aux données granulaires internes de la SNCF signaux de télédiagnostic embarqués, âge et kilométrage des rames, niveaux de

vibration, historique des réparations. L'écart mesuré chiffre précisément la valeur ajoutée attendue de ces données, et justifie l'investissement du module 1.

Évaluation du modèle LSTM

Métrique	Valeur obtenue	Objectif KPI	Statut
MAE	1,90%	< 3 %	Objectif respecté
RMSE	2,29%	< 3 %	Objectif respecté
Epoques d'entraînement	13/100	Max 100	Convergence rapide

Le modèle LSTM prédit le taux de régularité mensuelle des TGV (exprimé en pourcentage) à partir des douze mois précédents. Il obtient une erreur moyenne absolue (MAE) de 1,90 % et une erreur quadratique moyenne (RMSE) de 2,29 %, ces valeurs correspondant à des points de pourcentage d'écart sur le taux de régularité prédit. La MAE reste ainsi inférieure à l'objectif de 3 % fixé dans les KPIs, ce qui constitue un résultat satisfaisant sur une série de 135 mois marquée par des événements exceptionnels (COVID-19, grèves, Jeux Olympiques 2024) qui rendent la prévision particulièrement difficile.

La convergence rapide du modèle, atteinte en 13 époques sur les 100 planifiées grâce au mécanisme d'Early Stopping, confirme la bonne adéquation de l'architecture LSTM aux données. La val_loss minimale observée à l'époque 3 (0,0238) témoigne d'une bonne capacité de généralisation sur les données de test.

5.3 Visualisation des données

A. Choix des types de graphiques


Le choix des types de graphiques a été guidé par la nature des données et les objectifs analytiques de chaque visualisation. Six types de graphiques distincts ont été mobilisés, chacun adapté à un type d'analyse spécifique :

Type de graphique	Utilisation dans ce projet	Justification
Courbe temporelle	Évolution de la régularité 2015–2026	Idéal pour visualiser les tendances et ruptures dans une série chronologique
Barres horizontales	Causes des retards, Top 10 gares	Permet une comparaison claire entre catégories ordonnées

Histogramme	Distribution des retards	Révèle la forme de la distribution et les valeurs extrêmes
Boxplot	Retards par type de service	Compare la dispersion et les outliers entre groupes
Matrice de corrélation	Relations entre variables	Identifie les liens statistiques entre variables numériques
Camembert	Répartition des causes	Visualise les proportions d'un tout
Barres verticales	Saisonnalité mensuelle	Met en évidence les variations cycliques

B. Exploration visuelle des données


Graphique 1 — Évolution de la régularité et ponctualité TGV (2015–2026)



Ce graphique en courbes temporelles présente l'évolution mensuelle de deux indicateurs clés sur 135 mois : la régularité composite (en bleu) et la ponctualité à l'origine (en rouge). La ligne verte pointillée matérialise l'objectif de 90% fixé par la SNCF.

Plusieurs enseignements majeurs se dégagent de cette visualisation. Premièrement, la régularité composite oscille globalement autour de 90%, avec des pics à plus de 95% et des creux significatifs en dessous de 80%. Deuxièmement, la zone orange met en évidence la période COVID-19 (mars 2020 – juin 2021), durant laquelle le trafic réduit a mécaniquement amélioré les indicateurs de ponctualité avant une reprise progressive. Troisièmement, la ponctualité à l'origine est systématiquement inférieure à la régularité composite, confirmant que les retards s'accumulent tout au long des trajets. Ce graphique justifie pleinement le besoin d'un système de prédiction des retards capable d'anticiper les dégradations avant qu'elles ne surviennent.


Graphique 2 — Répartition moyenne des causes de retards TGV



Ce graphique en barres horizontales présente la répartition moyenne des six catégories de causes de retards sur l'ensemble du Dataset 2 (12 544 observations). Les résultats révèlent que l'infrastructure et les causes externes constituent les deux premières sources de retards, à quasi-égalité (environ 21,8 % chacune), suivies de la gestion du trafic (20,4 %). Le matériel roulant arrive en quatrième position avec 18,9 %, devant la prise en charge des voyageurs (7,6 %) et la gestion en gare (7,4 %).


Ce résultat est stratégiquement important : si les causes externes sont par définition difficiles à maîtriser, les causes liées à l'infrastructure et au matériel roulant, qui représentent ensemble plus de 40% des retards, constituent des leviers d'action prioritaires pour la maintenance prédictive. C'est précisément sur ces deux catégories que le module 1 du projet se concentre.

Graphique 3 — Top 10 gares SNCF par fréquentation (2024)




Ce graphique en barres horizontales classe les dix gares SNCF les plus fréquentées en 2024 en nombre de voyageurs. Sans surprise, les grandes gares parisiennes (Paris Montparnasse, Paris Gare de Lyon, Paris Saint-Lazare, Paris Nord) dominent largement le classement, reflétant le modèle radial du réseau ferroviaire français centré sur la capitale. Cette visualisation est directement utile pour le module 3 (Expérience Voyageur) : les efforts de personnalisation et d'amélioration de l'expérience client doivent être prioritairement concentrés sur ces gares à fort trafic, où l'impact potentiel sur la satisfaction des voyageurs est le plus élevé.

Graphique 4 — Distribution et boxplot des retards TGV



Ce graphique double présente deux analyses complémentaires de la distribution des retards moyens à l'arrivée. L'histogramme (gauche) révèle une distribution asymétrique à droite, avec une concentration des observations entre 20 et 50 minutes et une queue longue vers les valeurs élevées (jusqu'à 299,6 minutes pour le retard maximum observé). La moyenne de 35,5 minutes est supérieure à la médiane de 33,8 minutes, confirmant l'effet des valeurs extrêmes. Le boxplot (droite) compare la distribution des retards entre les services Nationaux et Internationaux, permettant d'identifier les différences de comportement entre ces deux segments. Cette analyse justifie le choix d'un algorithme LSTM pour la prédiction des retards, capable de modéliser des distributions non-gaussiennes et des valeurs extrêmes.


Graphique 5 — Matrice de corrélation des variables clés



La matrice de corrélation visualise les relations linéaires entre les huit variables numériques les plus importantes du Dataset 2. L'analyse révèle l'absence de corrélation linéaire forte : aucune paire de variables ne dépasse 0,27 en valeur absolue. Le retard moyen à l'arrivée est faiblement corrélé aux causes externes (0,25) et au nombre de trains en retard de plus de 15 minutes (0,15).

Par ailleurs, les différentes catégories de causes de retards présentent entre elles des corrélations négatives, faibles à modérées, jusqu'à $-0,27$). Ce résultat s'explique par leur nature compositionnelle : ces variables étant exprimées en pourcentages d'un même total, l'augmentation du poids d'une cause s'accompagne mécaniquement d'une diminution des autres. Cette faiblesse des corrélations linéaires ne disqualifie pas ces variables pour le modèle Random Forest, qui est précisément capable de capturer des relations non linéaires entre les variables explicatives et la cible. Surtout, l'absence de corrélations élevées entre variables explicatives confirme l'absence de multi-colinéarité excessive, qui aurait pu biaiser l'interprétation de l'importance des variables.

Graphique 6 — Saisonnalité mensuelle des retards TGV



Ce graphique en barres verticales met en évidence la saisonnalité des retards moyens à l'arrivée selon le mois de l'année. La barre rouge signale le mois présentant le retard moyen le plus élevé. Ce graphique révèle une saisonnalité marquée, avec des retards plus importants durant les mois d'hiver (décembre, janvier), liés aux conditions météorologiques et durant les périodes de forte fréquentation estivale. Les mois de septembre et octobre présentent généralement les meilleures performances, correspondant à une période de trafic modéré après le pic estival. La ligne verte pointillée matérialise la moyenne annuelle, permettant d'identifier visuellement les mois au-dessus et en dessous de la performance moyenne.

Cette saisonnalité est un paramètre essentiel intégré dans le modèle LSTM via la fenêtre temporelle de 12 mois.

C. Tableau de bord (Dashboard) Synthèse analytique

Dashboard IA — Maintenance Prédictive & Expérience Voyageur SNCF



Le Dashboard final synthétise l'ensemble des analyses dans une vue unifiée structurée en trois niveaux de lecture. Le premier niveau présente trois KPIs stratégiques en bandeau supérieur : la régularité moyenne 2024, le retard moyen à l'arrivée (35,2 minutes) et la part du matériel roulant dans les causes de retards (18,9%). Ces indicateurs offrent une lecture immédiate de la performance opérationnelle de la SNCF.

Le deuxième niveau combine la courbe temporelle de la régularité depuis 2015 avec le camembert de répartition des causes de retards, permettant de contextualiser les tendances historiques avec leurs facteurs explicatifs.

Le troisième niveau articule l'analyse de saisonnalité mensuelle avec le classement des cinq gares les plus fréquentées, croisant ainsi la dimension temporelle et la dimension géographique de l'analyse.

Ce Dashboard constitue l'outil de pilotage central du projet, destiné aux équipes opérationnelles de la SNCF. Il permet de suivre en un coup d'œil l'évolution des indicateurs clés, d'identifier les périodes et liaisons à risque, et d'orienter les décisions de maintenance préventive. Dans sa version finale déployée en production, ce Dashboard serait mis à jour automatiquement à chaque nouveau jeu de données mensuel, offrant une vision dynamique et temps réel de la performance du réseau ferroviaire.

6. Conclusion

Ce mémoire professionnel a permis d'explorer en profondeur l'écosystème de la SNCF, deuxième groupe de transport mondial, à un moment charnière de son histoire. Délestée de 35 milliards d'euros de dettes depuis 2020, transformée en société anonyme à capitaux publics, et confrontée pour la première fois à une concurrence réelle sur ses lignes TGV avec Trenitalia et Renfe, la SNCF doit démontrer qu'elle peut être aussi agile qu'un opérateur privé tout en préservant sa mission de service public.

L'analyse de marché a révélé une dynamique ferroviaire exceptionnellement positive en France : records de fréquentation pour la troisième année consécutive, progression historique de la part modale du rail à 10,5%, et chiffre d'affaires groupe de 43,4 milliards d'euros en 2024. Mais elle a également mis en lumière les vulnérabilités structurelles de l'opérateur : infrastructure vieillissante, insatisfaction sur la ponctualité et pression concurrentielle croissante sur les axes TGV stratégiques.

C'est précisément dans ce contexte que s'inscrit la solution proposée : un système intégré de Data Intelligence ferroviaire en trois modules, piloté en méthode Agile Scrum sur 9 mois, conduit en autonomie, pour un investissement estimé à 455 000 euros dans le cadre d'un déploiement industriel. Les modèles développés ont produit des résultats honnêtes et vérifiés : Les modèles développés ont produit des résultats à la fois honnêtes et instructifs : sur des données strictement indépendantes de la cible, le Random Forest atteint une AUC-ROC de 0,701 tandis que le modèle LSTM obtient une MAE de 1,90 %, inférieure à l'objectif de 3 %. L'écart entre la performance du Random Forest et sa cible de production démontre une conclusion majeure du projet : la maintenance réellement prédictive exige les données granulaires internes de la SNCF, que l'open data agrégée ne peut remplacer.

Contraintes du projet

Ce projet s'est heurté à plusieurs contraintes importantes qu'il convient d'identifier honnêtement. La première contrainte est d'ordre data : les données open data SNCF, bien que riches et

récentes, restent des données agrégées à l'échelle mensuelle et par liaison. Elles ne permettent pas de descendre au niveau de granularité du train individuel ou du composant technique précis, ce qui limite la précision des modèles de maintenance prédictive par rapport à ce qui serait possible avec les données IoT temps réel des capteurs embarqués. La deuxième contrainte est temporelle : ce projet a été conduit en totale autonomie, sans équipe dédiée, ce qui a nécessité une organisation rigoureuse et une priorisation constante des tâches. Les phases de collecte, nettoyage et modélisation des données se sont révélées particulièrement chronophages dans ce contexte de travail individuel. La troisième contrainte est réglementaire : l'intégration des données comportementales de SNCF Connect dans le module 3 nécessite un cadre RGPD rigoureux et l'accord explicite de la Direction Juridique du groupe, ce qui constitue un prérequis non négociable avant toute mise en production.

Risques identifiés

Trois catégories de risques ont été identifiées. Le premier risque est technique : les modèles entraînés sur des données historiques peuvent voir leurs performances se dégrader face à des événements atypiques non représentés dans les données d'entraînement (grèves massives, catastrophes naturelles, nouveaux types de pannes). Une surveillance continue des performances en production via un système de monitoring MLOps est indispensable pour détecter et corriger ces dérives. Le deuxième risque est organisationnel : l'adoption de ces outils par les équipes métier de la SNCF ne va pas de soi. La résistance au changement, la méfiance envers les décisions algorithmiques et le manque de culture data chez certains profils opérationnels constituent des obstacles réels à l'implémentation. Un plan de conduite du changement et des formations adaptées sont nécessaires pour garantir l'adoption effective des outils. Le troisième risque est budgétaire : un dépassement du budget prévisionnel de 455 000 euros est possible si les itérations sur les modèles s'avèrent plus nombreuses que prévu, si l'accès aux données internes SNCF est retardé, ou si les coûts d'infrastructure cloud dépassent les estimations initiales. La réserve pour aléas de 43 000 euros (10%) a été provisionnée précisément pour couvrir ces dépassements potentiels.

Enjeux du projet

Les enjeux de ce projet dépassent largement le cadre technique. Sur le plan compétitif, la SNCF dispose avec son écosystème de données d'un avantage concurrentiel structurel que Trenitalia et Renfe ne peuvent pas répliquer à court terme. Capitaliser sur cet actif via l'intelligence artificielle est une nécessité stratégique pour maintenir la différenciation face à des concurrents qui n'ont pas encore de présence nationale. Sur le plan opérationnel, chaque minute de retard évitée représente une économie mesurable : réduction des indemnités versées aux voyageurs, optimisation des rotations de matériel roulant, diminution des coûts de maintenance corrective d'urgence. Sur le plan sociétal, améliorer la fiabilité et l'expérience ferroviaire contribue directement aux objectifs de décarbonation de la mobilité en France : un voyageur satisfait par le train est un voyageur qui ne revient pas à la voiture ou à l'avion. Enfin, sur le

plan de l'image, la SNCF a tout à gagner à se positionner comme un leader de l'IA ferroviaire en Europe, renforçant ainsi son attractivité auprès des talents data et sa crédibilité auprès des autorités de régulation.

Perspectives d'évolution

Ce projet constitue une première brique d'un écosystème data plus large. Plusieurs évolutions majeures sont envisageables à moyen et long terme.

La première évolution naturelle est le déploiement d'une plateforme MLOps centralisée, permettant d'automatiser l'entraînement, le monitoring et la mise à jour des modèles en production. Cette plateforme garantirait la pérennité des performances des modèles dans le temps et faciliterait leur maintenance par les équipes data de la SNCF.

La deuxième évolution concerne l'enrichissement des sources de données. L'intégration de données multimodales (météorologiques temps réel, données de signalisation ERTMS, données de consommation énergétique des rames) permettrait d'améliorer significativement la précision des modèles de maintenance prédictive et d'atteindre le F1-Score cible de 0,85.

La troisième évolution porte sur l'extension géographique du projet. Les modules développés pour le réseau TGV pourraient être adaptés aux réseaux TER et Transilien, qui présentent des problématiques similaires de maintenance et d'expérience voyageur mais avec des spécificités propres (fréquence plus élevée, distances plus courtes, clientèle navetteurs).

Enfin, la quatrième perspective concerne la contribution aux objectifs de décarbonation du groupe. En optimisant les tournées de maintenance et en réduisant les pannes qui génèrent des trajets à vide ou des substitutions par autocar, ce projet contribue indirectement à la réduction des émissions CO2 de la SNCF, en cohérence avec son objectif de réduction de 50% des émissions d'ici 2030.

La SNCF dispose des actifs, des données et des ambitions pour être un leader de l'intelligence artificielle ferroviaire en Europe. Ce projet démontre que la voie est techniquement réalisable et économiquement justifiée, même dans le cadre d'une démarche individuelle. L'enjeu est désormais l'accélération opérationnelle et l'adoption à grande échelle.

7. Annexes

Annexe 1 : Références bibliographiques

Rapports SNCF :

- SNCF Réseau (2024). Rapport d'activité 2023.
<https://www.sncf-reseau.com/fr/rapport-annuel>
- SNCF Voyageurs (2024). Données de fréquentation et satisfaction client 2023-2024.
<https://www.sncf-voyageurs.com/fr/resultats-et-publications>
- SNCF Groupe (2024). Plan stratégique SNCF 2024-2030.
<https://www.sncf.com/fr/groupe/strategie>
- SNCF Réseau (2023). Rapport annuel sur la performance du réseau ferré national.
<https://www.sncf-reseau.com/fr/performance>

Autorités de régulation :

- ART (2024). Rapport annuel 2024 sur le marché français du transport ferroviaire.
<https://www.autorite-transports.fr/rapports-annuels>
- ART (2024). Observatoire de la concurrence dans le transport ferroviaire.
<https://www.autorite-transports.fr/observatoire>
- Cour des Comptes (2023). La situation et les perspectives des finances publiques.
<https://www.ccomptes.fr/fr/publications>
- Ministère de la Transition Écologique (2024). Stratégie nationale bas-carbone.
<https://www.ecologie.gouv.fr/strategie-nationale-bas-carbone-snbc>
- Ministère des Transports (2024). Statistiques annuelles des transports 2023.
<https://www.statistiques.developpement-durable.gouv.fr/>

Textes réglementaires :

- Règlement (UE) 2016/679 — RGPD. Journal officiel de l'Union européenne.
- Règlement (UE) 2021/782 relatif aux droits des voyageurs ferroviaires. Journal officiel de l'Union européenne.
- Loi n°2019-1428 du 24 décembre 2019 — Loi d'Orientation des Mobilités (LOM). Journal officiel de la République française.

Annexe 2 — Sources de données utilisées

Dataset	URL	Format	Licence
Régularité TGV nationale	https://ressources.data.sncf.com/explore/dataset/reglarite-mensuelle-tgv-nationale/	CSV	ODbL
Régularité TGV par liaisons	https://ressources.data.sncf.com/explore/dataset/regularite-mensuelle-tgv-aqst/	CSV	ODbL
Fréquentation des gares	https://ressources.data.sncf.com/explore/dataset/frequentation-gares/	CSV	ODbL

Annexe 3 — Résultats des modèles

Random Forest — Rapport de classification :

Classe	Précision	Rappel	F1-Score	Support
Risque Faible	0,64	0,64	0,64	1 826
Risque Élevé	0,64	0,64	0,64	1 829
Moyenne	0,64	0,64	0,64	3 655

AUC-ROC : 0,701

F1-Score CV 5-fold : $0,642 \pm 0,005$

LSTM — Performances :

MAE : 1,90% — RMSE : 2,29% — Convergence : époque 13/100

Annexe 4 : Lien Google Colab :

<https://colab.research.google.com/drive/1NkQMyJB41aZsc7PdlvAmQhagdMOiWhwc?usp=sharing>